

2. シーケンス図 — 登録と質問応答の通信 (webRagSys_Django)

この図は何を示すか

登録時と質問時の、登場人物間の呼び出し順序を示す。たとえるなら電話の取次ぎ記録である。

なぜ必要か

RAGは複数の関数をつなぐ仕組みであり、順序を間違えると回答の根拠が空になるためである。

読み方

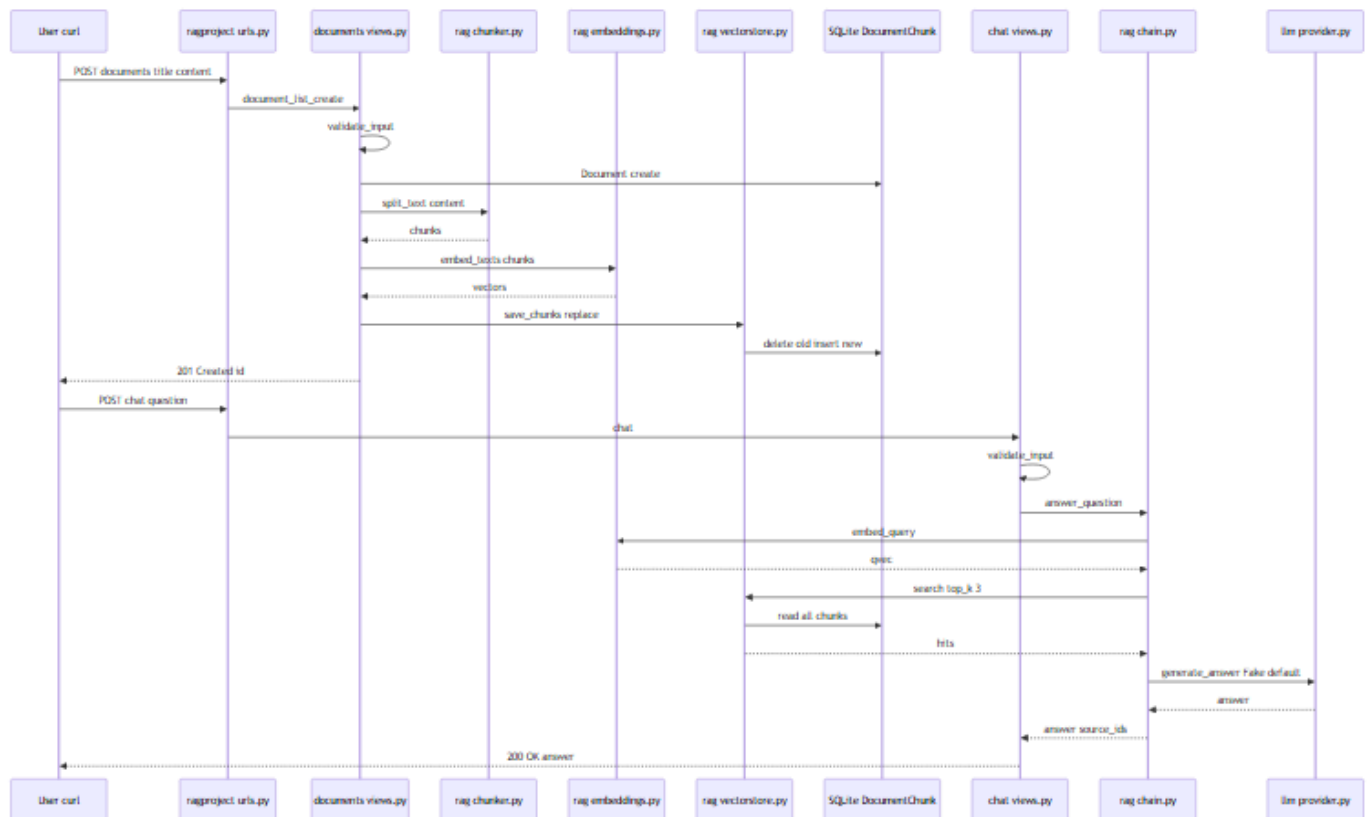
上から下へ時間が進む。矢印が呼び出し、破線矢印が戻り値である。

初心者が混乱しやすい点

- 登録時にLLMは呼ばれない。分割とベクトル化だけである
- 質問時にDBへの保存は行わない。読取だけである
- `save_chunks` は置換方式である。古いベクトルを消してから入れる
- 質問のベクトル化 (`embed_query`) を忘れると検索が始まらない

実コードとの対応

- `documents/views.py:40-56` : 登録本体、保存後に分割と保存
- `rag/vectorstore.py:41-58` : 置換保存、64-70行目が削除、73-90行目が検索
- `rag/chain.py` : 検索→整形→生成の順序決定
- `chat/views.py:40-49` : 本体はchainへの委譲だけ



► 図の元データ (Mermaid)