

3a. クラス図（RAG） — 分割・検索・生成の関係 (webRagSys_Django)

この図は何を示すか

RAGを担う部品と、その使う使われる関係を示す。たとえるなら索引係の分業表である。

なぜ必要か

中心が `chain.py` であり、LLMがRAGを使うのではないことを明確にするためである。

読み方


矢印の根元が使う側、先端が使われる側である。Chain から3本出る。

初心者が混乱しやすい点

- LangChainはここでは分割道具（TextSplitter）だけである。鎖状の高度機能は使わない
- FakeProvider は本番の代役である。課金を避けるための偽回答係である
- DocumentChunk はテーブル定義であり、計算は VectorStore が担う
- embedding 列はJSON列である。専用ベクトル型ではない

実コードとの対応

- `rag/chunker.py` : `split_text`、LangChain優先・単純分割退避
- `rag/embeddings.py` : `embed_texts`、`embed_query`、偽ベクトル8次元
- `rag/vectorstore.py`:25-38 : コサイン計算、73-90行目が検索
- `rag/chain.py` : 検索と生成の順序決定
- `llm/provider.py` : `USE_FAKE=true` 既定で偽回答
- `documents/models.py`:39-59 : DocumentChunk 定義



► 図の元データ（Mermaid）